Aula 3 — Respostas das atividades

Componente	Projeto Profissional de Análise de Dados
Unidade	Unidade 2 — Coleta, organização e preparação dos dados
Projeto-base	Login System → Dashboard de Análise de Dados
Integrantes	Jacob Almeida, Carlos Henrique, Junio e Jhullyana
Base escolhida	Turmas das Escolas do Futuro - SECTI (Portal de Dados Abertos do Estado de Goiás)
Data	08/10/2026

9. Atividade 1 — Confirmando a base

Sobre a fonte

Pergunta	Resposta
1. Quem produziu os dados?	A Secretaria de Estado de Ciência, Tecnologia e Inovação de Goiás (SECTI-GO). Os dados vêm do Sistema de Gerenciamento Acadêmico das Escolas do Futuro (SIGA) e são mantidos pela Gerência de Tecnologia da SECTI.
2. A instituição é confiável?	Sim. A SECTI é o órgão do Governo de Goiás ao qual as Escolas do Futuro estão vinculadas, e a base está no Portal de Dados Abertos do próprio Estado, com autor, mantenedor, fonte do sistema e licença Creative Commons Atribuição (CC-BY) identificados. Isso permite rastrear e citar a origem.
3. Qual é o endereço da fonte?	https://dadosabertos.go.gov.br/dataset/turmas-escolas-do-futuro
4. Qual é o nome da base?	Turmas das Escolas do Futuro - SECTI (arquivos turmasefg_AAAAMM.csv, um por semestre).
5. Qual é o período dos dados?	Do 1º semestre de 2022 ao 1º semestre de 2026, em 9 arquivos CSV semestrais (202201, 202202, 202301, 202302, 202401, 202402, 202501, 202502 e 202601). A base foi criada em 03/06/2025 e atualizada em 08/10/2026.

Sobre o conteúdo

Pergunta	Resposta
6. O que a base representa?	As turmas em execução nas Escolas do Futuro de Goiás: cada turma tem escola, curso, modalidade, turno, datas, vagas e matrículas. Ela retrata a oferta de formação da rede ao longo do tempo.
7. O que cada linha representa?	Uma turma (identificada por id_turma). A base é de turmas, e não de alunos: não há dados individuais de estudantes.
8. O que cada coluna representa?	Uma característica da turma. São 15 colunas, descritas no quadro abaixo. O dicionário oficial descreve apenas 4 delas (status_turma, carga_horaria, matriculas_turma e matriculas_aptas), repetindo o próprio nome do campo; as demais foram interpretadas pela equipe a partir dos nomes e dos valores.
9. Quais são as principais variáveis?	escola, curso, categoria, modalidade e turno (para agrupar e comparar); data_inicio e data_fim (evolução no tempo); qtde_vagas, matriculas_turma e matriculas_aptas (indicadores numéricos); status_turma (filtrar turmas concluídas e não iniciadas).
10. A base possui os dados necessários para responder à pergunta principal?	Sim, em grande parte. Ela permite analisar a evolução de turmas e matrículas, a distribuição por escola e curso e o preenchimento de vagas. Não permite analisar evasão, perfil ou desempenho dos alunos, porque não há dados individuais. Detalhes na matriz do item 20.

Quadro das 15 colunas:

Coluna	Significado	Tipo esperado	Será usada?
id_turma	Identificador numérico da turma.	Inteiro	Sim (chave)
turma	Código da turma (ex.: QP-JLB-ACCN-I1-2026), que reúne categoria, escola, curso, turno/modalidade e ano.	Texto	Talvez

escola	Unidade das Escolas do Futuro em que a turma funciona.	Texto	Sim
projeto	Programa ou projeto ao qual a turma pertence.	Texto	Talvez
categoria	Tipo de oferta (ex.: capacitação ou qualificação profissional).	Texto	Sim
curso	Nome do curso ofertado.	Texto	Sim
modalidade	Forma de oferta da turma (ex.: presencial ou on-line).	Texto	Sim
qtde_vagas	Quantidade de vagas ofertadas na turma.	Inteiro	Sim
turno	Turno em que a turma funciona.	Texto	Sim
data_inicio	Data de início da turma.	Data	Sim
data_fim	Data de término da turma.	Data	Sim
status_turma	Situação da turma (ex.: Não Iniciado, Concluído).	Texto	Sim
carga_horaria	Carga horária do curso, em horas.	Inteiro	Talvez
matriculas_turma	Quantidade de matrículas na turma.	Inteiro	Sim
matriculas_aptas	Quantidade de matrículas consideradas aptas; o dicionário oficial não explica o critério.	Inteiro (vem com “-” em turmas sem dado)	Sim, com cuidado

10. Atividade 2 — Abrindo a base

Ferramenta utilizada	Google Colab com Python/Pandas (também é possível abrir no Excel ou no Google Sheets, mas o Pandas lê direto do endereço do arquivo).

Arquivo aberto	turmasefg_202601.csv (1º semestre de 2026), o mais recente. Os demais seguem a mesma estrutura de colunas e podem ser abertos do mesmo jeito.
Formato	CSV, com campos entre aspas duplas e ponto e vírgula (;) como separador. O arquivo começa com um marcador BOM, então a leitura deve usar encoding="utf-8-sig".

Passo a passo

• Abrir o Google Colab e criar um novo notebook.
• Ler o arquivo direto do endereço do portal com pd.read_csv, informando sep=";" e encoding="utf-8-sig" (código completo no item 22).
• Se o portal bloquear a leitura direta, baixar o arquivo no computador, enviá-lo ao Colab e salvar uma cópia intacta em data/dados_original.csv.
• Apenas observar: não alterar, preencher ou excluir nada nesta aula.

Primeira observação da base (o que estou vendo?)

Nomes das colunas	id_turma, turma, escola, projeto, categoria, curso, modalidade, qtde_vagas, turno, data_inicio, data_fim, status_turma, carga_horaria, matriculas_turma, matriculas_aptas (15 colunas).
Quantidade de linhas	[resultado de dados.shape no Colab]
Categorias	status_turma traz valores como “Não Iniciado” e “Concluído”; a coluna categoria traz tipos de oferta como qualificação.
Datas	data_inicio e data_fim, que permitem organizar as turmas por período.
Números	qtde_vagas, carga_horaria, matriculas_turma e matriculas_aptas.
Textos	turma (código com escola, curso e ano), escola, projeto, categoria, curso, modalidade, turno e status_turma.
Células vazias ou marcadas	Nas turmas com status “Não Iniciado”, matriculas_aptas aparece com o sinal “-” em vez de número (ex.: turmas 8877 e 8874). [confirmar no Colab se há outras colunas com vazios]

18. Atividade 3 — Raio-X da base

Informação	Resultado
Nome da base	Turmas das Escolas do Futuro - SECTI
Fonte	https://dadosabertos.go.gov.br/dataset/turmas-escolas-do-futuro
Instituição responsável	Secretaria de Estado de Ciência, Tecnologia e Inovação de Goiás (SECTI-GO); dados do sistema SIGA.
Período	1º semestre de 2022 a 1º semestre de 2026 (9 arquivos semestrais).
Formato	CSV, separador “;”, campos entre aspas, com BOM (utf-8-sig).
Quantidade de registros	[dados.shape, primeiro número, do arquivo 202601; repetir para os demais ou somar]
Quantidade de colunas	15
Principais variáveis	escola, curso, categoria, modalidade, turno, data_inicio, data_fim, status_turma, qtde_vagas, matriculas_turma, matriculas_aptas.
Valores ausentes	matriculas_aptas vem com “-” nas turmas não iniciadas, o que é ausência de informação e não um número. Demais colunas: [dados.isnull().sum()]
Possíveis duplicidades	[dados.duplicated().sum() e dados["id_turma"].duplicated().sum()]
Possíveis inconsistências	O dicionário oficial escreve os nomes dos campos em maiúsculas (STATUS_TURMA) e o CSV usa minúsculas (status_turma). A base está dividida em 9 arquivos, e é preciso conferir se todos têm as mesmas colunas e os mesmos nomes de escola e de curso. [variações de escrita encontradas]
Observações	O dicionário descreve só 4 das 15 colunas e apenas repete os rótulos, sem explicar, por exemplo, o critério de “matrículas aptas”. Os ids de turma têm lacunas (ex.: de 8877 a 8375 há números ausentes), o que é esperado em uma base que mostra apenas turmas em execução. A frequência de atualização informada é anual.

20. Atividade 4 — Matriz Pergunta × Dados

Pergunta principal (proposta): como evoluíram a oferta de turmas e as matrículas nas Escolas do Futuro entre 2022 e 2026, e quais escolas e cursos concentram maior procura e melhor preenchimento das vagas?

Pergunta	Dados necessários	Existem na base?	Colunas
1. Como evoluiu o número de turmas entre 2022 e 2026?	Identificação da turma + período	Sim	id_turma, data_inicio (e o semestre do arquivo)
2. Quais escolas e cursos têm mais matrículas?	Escola, curso e número de matrículas	Sim	escola, curso, matriculas_turma
3. Qual o preenchimento das vagas por modalidade e turno?	Vagas, matrículas, modalidade e turno	Sim	qtde_vagas, matriculas_turma, modalidade, turno
4. Qual a proporção de matrículas aptas por categoria ou curso?	Matrículas aptas, matrículas e categoria	Parcialmente	matriculas_aptas, matriculas_turma, categoria (faltam valores nas turmas não iniciadas e o dicionário não define “apta”)
5. Qual a taxa de evasão dos alunos?	Matrículas que abandonaram o curso, por turma	Não	—
6. Qual o perfil dos alunos (idade, município, gênero)?	Dados individuais dos estudantes	Não	—

22. Atividade 5 — Primeira experiência com Python

Código para colar no Google Colab. Ele só lê e inspeciona a base, sem alterar nada.

Passo 1 — abrir a base

import pandas as pd

url="https://dadosabertos.go.gov.br/dataset/3462c48e-67ce-4b3c-9b4c-36c8d5db9f1d/resource/31f75c82-3926-4359-8acc-911586b2ebe6/download/turmasefg_202601.csv"dados = pd.read_csv(url, sep=";", encoding="utf-8-sig")

dados.head()

Se o portal recusar a leitura direta, baixar o arquivo, enviá-lo ao Colab e usar

pd.read_csv("dados_original.csv", sep=";", encoding="utf-8-sig")

Passo 2 — conhecer a estrutura

dados.shape # (linhas, colunas)
dados.columns # nomes das colunas
dados.info() # tipos de dados e valores não nulos
dados.isnull().sum() # valores ausentes por coluna
(dados == "-").sum() # células marcadas com "-" (ex.: matriculas_aptas)
dados.duplicated().sum() # linhas totalmente repetidas
dados["id_turma"].duplicated().sum() # ids de turma repetidos
dados.describe() # estatísticas das colunas numéricas

Comando	O que mostra	Resultado nesta base
dados.head()	Os primeiros registros.	Cada linha é uma turma, ex.: id 8661, turma CP-PAURENAT-PCTOFF-N 4-2026, Concluído, 30 matrículas e 14 aptas.
dados.shape	(linhas, colunas).	[linhas] linhas e 15 colunas.
dados.columns	Os nomes das colunas.	id_turma, turma, escola, projeto, categoria, curso, modalidade, qtde_vagas, turno, data_inicio, data_fim, status_turma, carga_horaria, matriculas_turma, matriculas_aptas.

dados.info()	Tipos de dados e valores não nulos.	[colar]. Atenção: por causa do “-”, matriculas_aptas tende a ser lida como texto (object) e não como número.
dados.isnull().sum()	Valores ausentes por coluna.	[colar]
dados.describe()	Média, desvio, mínimo, máximo e quartis.	[colar; interpretar só o básico por enquanto]

27. “Conhecer antes de analisar” — fórum

Pergunta norteadora: por que um profissional de análise de dados precisa conhecer e verificar a qualidade de uma base antes de iniciar uma análise?

Porque uma análise só é tão confiável quanto os dados que a sustentam. Antes de qualquer gráfico, é preciso saber a origem dos dados: quem os produziu, em que período e para quê. Na nossa base, por exemplo, sabemos que ela vem do sistema acadêmico das Escolas do Futuro, publicada pela SECTI, e que cobre do 1º semestre de 2022 ao 1º semestre de 2026. Isso mostra que a fonte é oficial e que o período serve para analisar evolução.

Interação com um colega

Pergunta: você encontrou algum problema na base escolhida pelo colega que poderia comprometer a análise? Explique.